

关于温度计读数实例讲解 kalman

在学习卡尔曼滤波器之前，首先看看为什么叫“卡尔曼”。跟其他著名的理论（例如傅立叶变换，泰勒级数等等）一样，卡尔曼也是一个人的名字，而跟他们不同的是，他是个现代人！

卡尔曼全名 Rudolf Emil Kalman，匈牙利数学家，1930 年出生于匈牙利首都布达佩斯（哈哈，布达佩斯——陈佩斯和他哥哥陈布达名字的根源）。1953，1954 年于麻省理工学院分别获得电机工程学士及硕士学位。

1957 年于哥伦比亚大学获得博士学位。我们现在要学习的卡尔曼滤波器，正是源于他的博士论文和 1960 年发表的论文《A New Approach to Linear Filtering and Prediction

Problems》（线性滤波与预测问题的新方法）。如果对这篇论文有兴趣，可以到这里的地址下载：

<http://www.cs.unc.edu/~welch/kalman/media/pdf/Kalman1960.pdf>

简单来说，卡尔曼滤波器是一个“optimal recursive data processing algorithm（最优化自回归数据处理算法）”。对于解决很大部分的问题，他是最优，效率最高甚至是最有用的。他的广泛应用已经超过 30 年，包括机器人导航，控制，传感器数据融合甚至在军事方面的雷达系统以及导弹追踪等等。近年来更被应用于计算机图像处理，例如头脸识别，图像分割，图像边缘检测等等。

1. 卡尔曼滤波器的介绍（Introduction to the Kalman Filter）

为了可以更加容易的理解卡尔曼滤波器，这里会应用形象的描述方法来讲解，而不是像大多数参考书那样罗列一大堆的数学公式和数学符号。但是，他的 5 条公式是其核心内容。结合现代的计算机，其实卡尔曼的程序相当的简单，只要你理解了他的那 5 条公式。

在介绍他的 5 条公式之前，先让我们来根据下面的例子一步一步的探索。

假设我们要研究的对象是一个房间的温度。根据你的经验判断，这个房间的温度是恒定的，也就是下一分钟的温度等于现在这一分钟的温度（假设我们用一分钟来做时间单位）。

假设你对你的经验不是 100% 的相信，可能会有上下偏差几度。

我们把这些偏差看成是高斯白噪声（White Gaussian Noise），

也就是这些偏差跟前后时间是没有关系的而且符合高斯分配（Gaussian Distribution）。

另外，我们在房间里放一个温度计，但是这个温度计也不准确的，测量值会比实际值偏差。

我们也把这些偏差看成是高斯白噪声。

好了，现在对于某一分钟我们有两个有关于该房间的温度值：

你根据经验的预测值（系统的预测值）和温度计的值（测量值）。

目标：

下面我们要用这两个值结合他们各自的噪声来估算出房间的实际温度值。

假如我们要估算 k 时刻的是实际温度值。

首先你要根据 $k-1$ 时刻的温度值，来预测 k 时刻的温度。

因为你相信温度是恒定的，所以你会得到 k 时刻的温度预测值是跟 $k-1$ 时刻一样的，

假设是 23 度，同时该值的高斯噪声的偏差是 5 度（5 是这样得到的：如果 $k-1$ 时刻估算出的最优温度值的偏差是 3，你對自己预测的不确定度是 4 度，他们平方相加再开方，就是 5）。

然后，你从温度计那里得到了 k 时刻的温度值，假设是 25 度，同时该值的偏差是 4 度。

由于我们用于估算 k 时刻的实际温度有两个温度值，分别是 23 度和 25 度。

究竟实际温度是多少呢？相信自己还是相信温度计呢？

究竟相信谁多一点，我们可以用他们的 *covariance* 来判断。

因为 $Kg^2 = 5^2 / (5^2 + 4^2)$ ，所以 $Kg = 0.78$ ，

我们可以估算出 k 时刻的实际温度值是： $23 + 0.78 * (25 - 23) = 24.56$ 度。

因为温度计的 *covariance* 比较小（比较相信温度计），

所以估算出的最优温度值偏向温度计的值。

现在我们已经得到 k 时刻的最优温度值了，

下一步就是要进入 $k+1$ 时刻，进行新的最优估算。

到现在为止，好像还没看到什么自回归的东西出现。

在进入 $k+1$ 时刻之前，我们还要算出 k 时刻那个最优值（24.56 度）的偏差。

算法如下：

$$((1 - Kg) * 5^2)^{0.5} = 2.35$$

这里的 5 就是上面的 k 时刻你预测的那个 23 度温度值的偏差，

得出的 2.35 就是进入 $k+1$ 时刻以后 k 时刻估算出的最优温度值的偏差（对应于上面的 3）。

就是这样，卡尔曼滤波器就不断的把 *covariance* 递归，从而估算出最优的温度值。

他运行的很快，而且它只保留了上一时刻的 *covariance*。

上面的 Kg ，就是卡尔曼增益（Kalman Gain）。他可以随不同的时刻而改变他自己的值。

下面就要言归正传，讨论真正工程系统上的卡尔曼。

2. 卡尔曼滤波器算法（The Kalman Filter Algorithm）

在这一部分，我们就来描述源于 Dr Kalman 的卡尔曼滤波器。下面的描述，会涉及一些基本的概念知识，包括概率（Probability），随即变量（Random Variable），

高斯或正态分配（Gaussian Distribution）还有 State-space Model 等等。

但对于卡尔曼滤波器的详细证明，这里不能一一描述。

首先，我们先要引入一个离散控制过程的系统。

该系统可用一个线性随机微分方程（Linear Stochastic Difference equation）来描述：

$$X(k) = A X(k-1) + B U(k) + W(k)$$

再加上系统的测量值：

$$Z(k) = H X(k) + V(k)$$

上两式子中：

$X(k)$ 是 k 时刻的系统状态，

$U(k)$ 是 k 时刻对系统的控制量。

A 和 B 是系统参数，对于多模型系统，他们为矩阵。

$Z(k)$ 是 k 时刻的测量值，

H 是测量系统的参数，对于多测量系统， H 为矩阵。

$W(k)$ 和 $V(k)$ 分别表示过程和测量的噪声。

他们被假设成高斯白噪声(White Gaussian Noise)，

他们的 *covariance* 分别是 Q , R （这里我们假设他们不随系统状态变化而变化）。

对于满足上面的条件(线性随机微分系统，过程和测量都是高斯白噪声)，卡尔曼滤波器是最优的信息处理器。

下面我们来用他们结合他们的 covariances 来估算系统的最优化输出（类似上节那温度的例子）。首先我们要利用系统的过程模型，来预测下一状态的系统。

假设现在的系统状态是 k ，根据系统的模型，可以基于系统的上一状态而预测出现在状态：

$$X(k|k-1)=A X(k-1|k-1)+B U(k) \dots\dots\dots (1)$$

式(1)中：

$X(k|k-1)$ 是利用上一状态预测的结果，

$X(k-1|k-1)$ 是上一状态最优的结果，

$U(k)$ 为现在状态的控制量，如果没有控制量，它可以为 0。

到现在为止，我们的系统结果已经更新了，可是，对应于 $X(k|k-1)$ 的 covariance 还没更新。

我们用 P 表示 covariance：

$$P(k|k-1)=A P(k-1|k-1) A' + Q \dots\dots\dots (2)$$

式(2)中：

$P(k|k-1)$ 是 $X(k|k-1)$ 对应的 covariance，

$P(k-1|k-1)$ 是 $X(k-1|k-1)$ 对应的 covariance，

A' 表示 A 的转置矩阵，

Q 是系统过程的 covariance。

式子 1, 2 就是卡尔曼滤波器 5 个公式当中的前两个也就是对系统的预测。

现在我们有了现在状态的预测结果，然后我们再收集现在状态的测量值。

结合预测值和测量值我们可以得到现在状态(k)的最优化估算值 $X(k|k)$ ：

$$X(k|k)= X(k|k-1)+K_g(k) (Z(k)-H X(k|k-1)) \dots\dots\dots (3)$$

其中 K_g 为卡尔曼增益(Kalman Gain)：

$$K_g(k)= P(k|k-1) H' / (H P(k|k-1) H' + R) \dots\dots\dots (4)$$

到现在为止，我们已经得到了 k 状态下最优的估算值 $X(k|k)$ 。

但是为了要另卡尔曼滤波器不断的运行下去直到系统过程结束，

我们还要更新 k 状态下 $X(k|k)$ 的 covariance：

$$P(k|k)= (I-K_g(k)H) P(k|k-1) \dots\dots\dots (5)$$

其中：

I 为 1 的矩阵，对于单模型单测量， $I=1$ 。

当系统进入 $k+1$ 状态时， $P(k|k)$ 就是式子(2)的 $P(k-1|k-1)$ 。

这样，算法就可以自回归的运算下去。

卡尔曼滤波器的原理基本描述了，式子 1, 2, 3, 4 和 5 就是他的 5 个基本公式。

根据这 5 个公式可以很容易的实现计算机的程序。

下面将会用程序举一个实际运行的例子。

3. 简单例子 (A Simple Example)

这里我们结合第二第三节，举一个非常简单的例子来说明卡尔曼滤波器的工作过程。所举的例子是进一步描述第二节的例子，而且还会配以程序模拟结果。

根据第二节的描述，把房间看成一个系统，然后对这个系统建模。当然，我们见的模型不需要非常地精确。我们所知道的这个房间的温度是跟前一时刻的温度相同的，所以 $A=1$ 。

没有控制量，所以 $U(k)=0$ 。因此得出：

$$X(k|k-1)=X(k-1|k-1) \quad \dots\dots\dots (6)$$

式子 (2) 可以改成：

$$P(k|k-1)=P(k-1|k-1)+Q \quad \dots\dots\dots (7)$$

因为测量的值是温度计的，跟温度直接对应，所以 $H=1$ 。式子 3, 4, 5 可以改成以下：

$$X(k|k)=X(k|k-1)+Kg(k)(Z(k)-X(k|k-1)) \quad \dots\dots\dots (8)$$

$$Kg(k)=P(k|k-1)/(P(k|k-1)+R) \quad \dots\dots\dots (9)$$

$$P(k|k)=(1-Kg(k))P(k|k-1) \quad \dots\dots\dots (10)$$

现在我们模拟一组测量值作为输入。假设房间的真实温度为 25 度，我模拟了 200 个测量值，这些测量值的平均值为 25 度，但是加入了标准偏差为几度的高斯白噪声（在图中为蓝线-没找到图）。

为了令卡尔曼滤波器开始工作，我们需要告诉卡尔曼两个零时刻的初始值，是 $X(0|0)$ 和 $P(0|0)$ 他们的值不用太在意，随便给一个就可以了，因为随着卡尔曼的工作， X 会逐渐的收敛。但是对于 P ，一般不要取 0，因为这样可能会令卡尔曼完全相信你给定的 $X(0|0)$ 是系统最优的，从而使算法不能收敛。我选了 $X(0|0)=1$ 度， $P(0|0)=10$ 。

该系统的真实温度为 25 度，图中用黑线表示。图中红线（没找到图）是卡尔曼滤波器输出的最优化结果（该结果在算法中设置了 $Q=1e-6$, $R=1e-1$ ）。

<http://hi.baidu.com/xjhjzjut/blog/item/87bddad35ae0e1053bf3cf37.html>

另：什么是 kalman 滤波器？

kalman 滤波器是一个最优化递归处理算法 (optimal recursive data processing algorithm)。

- (1) 最优 (optimal) 依赖于评价性能的判据。Kalman 滤波器充分利用如下信息估计感兴趣变量当前取值：a.系统和测量装置的动态特性；b.系统噪声、测量误差和动态模型的不确定性的统计描述；c.感兴趣变量的初始条件的相关信息。
- (2) 递归 (recursive) 是指 kalman 不需要保存先前的数据，当进行新的测量时也不需要对待原来数据进行处理。
- (3) filter (DPA) 实际上是数据处理算法，只不过是计算中处理的程序，因此能处理离散时间测量样本，而不是连续时间输入。

基本假设

采用线性模型是合理的；

这是典型工程模型在某些主要点或轨迹是线性的，线性模型比非线性模型更简单。
因此用线性模型来近似。

白噪声意味着噪声值和时间不相关；

白噪声指在整个频率上都有相同强度的频率特性的噪声。实际应用中将频率设为常值，带宽大大超过系统带宽的噪声称为白噪声，用高斯白噪声来模拟可以大大简化模型。

采用高斯密度函数在实践上是可行的

因为采用高斯函数在数学上容易处理。当缺少高阶统计量时，除了假定高斯密度外，没有更好的可以表示的函数形式。用一阶和二阶统计量完全可以描述高斯白噪声。